


Atividade#8 de Fundamentos de IA

RAG COM HUGGING FACE

Dupla = (Rodolfo Theodoro, Laryssa Theodoro)

ESCOLHA TÉCNICA

Escolhemos a temática de **RAG** (Retrieval-Augmented Generation), uma arquitetura que evita alucinações em modelos de linguagem ao fornecer fontes de dados externas, confiáveis e mais limitadas. Para a implementação, utilizamos o ecossistema da **Hugging Face** proposta pelo professor, que é a principal plataforma de código aberto para IA no mundo, permitindo o acesso a modelos pré-treinados de alta performance através da biblioteca **transformers**. A escolha do RAG também se baseia pela necessidade de sistemas de IA que não apenas processem linguagem, mas que sejam capazes de consultar bases de conhecimento específicas e atualizadas em tempo real.




```
#Import das bibliotecas utilizadas
from transformers import pipeline
import wikipedia
```

```
# 1. RETRIEVAL (Com ajuste de limite)
wikipedia.set_lang("pt")
página = wikipedia.page("Twin Peaks")
base_de_dados = página.summary
```

```
# 2. MODELO HUGGING FACE
# Este modelo é excelente para o limite de tokens do Wikipedia Summary
modelo_ia = pipeline("question-answering", model="deepset/roberta-base-squad2")
```

A solução foi desenvolvida em Python via Google Colab, utilizando a biblioteca wikipedia para a etapa de Retrieval (Recuperação), extraindo informações diretamente da página da série *Twin Peaks*. Esta série foi escolhida como fonte de dados por detalhes muito específicos que testam a precisão do modelo e por nos permitir uma curadoria (já que gostamos da série). No fluxo do RAG, o conteúdo da Wikipedia é tratado e injetado como contexto no modelo da Hugging Face. Optamos pelo uso de um modelo especializado em Question Answering (como o RoBERTa), que analisa o texto recuperado para localizar a resposta exata, conectando a base de dados externa à capacidade de compreensão da IA.

IMPLEMENTAÇÃO

EXECUÇÃO



Durante a execução, o sistema foi testado com a pergunta: "Quem é o ator interpretando Dale Cooper?". O modelo processou o sumário da Wikipedia e retornou com precisão o nome do ator, demonstrando a eficácia do RAG em extrair dados pontuais sem a necessidade de re-treinar o modelo. Um desafio técnico superado foi a gestão da janela de contexto, ajustando o volume de dados recuperados para respeitar o limite de tokens do modelo.

O código completo, documentando todas as etapas desde a extração até a geração da resposta, está disponível no GitHub.

